## EAAMNIKH AMMOKAATIA MAKEAONIAE

# ΠΡΟΓΡΑΜΜΑ ΜΕΤΑΠΤΥΧΙΑΚΩΝ ΣΠΟΥΔΩΝ «ΤΕΧΝΗΤΗ ΝΟΗΜΟΣΥΝΗ & ΑΝΑΛΥΤΙΚΗ ΔΕΔΟΜΕΝΩΝ»

Μηχανική Μάθηση και Επεξεργασία Φυσικής Γλώσσας

#### 4η Εργασία (Μη επιβλεπόμενη μάθηση – Συσταδοποίηση)

Στην εργασία αυτή θα αναπτύξετε συνδυαστικά μοντέλα βαθιάς μάθησης / τεχνικών συσταδοποίησης (clustering), τα οποία θα χρησιμοποιήσετε πάνω στα δεδομένα του dataset **fashion-mnist**. Παρέχονται στο ακόλουθο link: <a href="https://github.com/zalandoresearch/fashion-mnist">https://github.com/zalandoresearch/fashion-mnist</a>.

Για την συγκεκριμένη άσκηση θα παραδώσετε ένα αρχείο σε python στο οποίο θα παρουσιάζετε τις διαφορές στα αποτελέσματα συσταδοποίησης όταν χρησιμοποιώντας ακατέργαστα (raw) δεδομένα και όταν χρησιμοποιούνται σύνθετα περιγραφικά χαρακτηριστικά (high level feature values), που εξήχθησαν με χρήση stacked autoencoders.

Ο κώδικας που θα αναπτύξετε πρέπει να κάνει τα ακόλουθα:

- 1. Θα φορτώνει τα δεδομένα του fashion-mnist.
- 2. Θα διαχωρίζει τα δεδομένα σε τρία σύνολα: train, validation & test data.
- 3. Θα δημιουργεί ένα CNN autoencoder που θα συμπιέζει και θα αναδημιουργεί την εικόνα εισόδου. Προσοχή: επιλέξτε όποια αρχιτεκτονική επιθυμείτε.
- 4. Θα τυπώνει τυχαία εικόνες από το dataset (μία από κάθε κλάση) καθώς και τις ανακατασκευασμένες, όπως αυτές παρέχονται από τον autoencoder.
- 5. Θα χρησιμοποιεί το τμήμα του encoder για να κωδικοποιεί τις εικόνες.
- 6. Θα χρησιμοποιεί τρεις διαφορετικές τεχνικές συσταδοποίησης (οποίες επιθυμείτε εσείς) για να δημιουργήσει υποομάδες.
- 7. Θα υπολογίζει τους δείκτες απόδοσης που παρουσιάστηκαν στο εργαστήριο και έναν ακόμα της επιλογή σας.
- 8. Θα παρουσιάζει ενδεικτικά αποτελέσματα ομαδοποίησης για τυχαίες εικόνες.
- 9. Τα βήματα 6, 7 και 8 θα εκτελεστούν χρησιμοποιώντας α) τις τιμές των pixel των εικόνων (κανονικοποιημένες στο [0,1] και β) τις τιμές των εικόνων που παράγει το κομμάτι του encoder στο CNN που κατασκευάσατε.
- 10. Χρησιμοποιώντας τα αποτελέσματα του αλγορίθμου, και γραφικές παραστάσεις που θα φτιάξετε στο excel, θα συντάξετε μια έκθεση στην οποία θα παρουσιάζετε τα συμπεράσματα σας, θα κάνετε συγκριτικές αξιολογήσεις και θα προτείνετε ποια είναι η καλύτερη δυνατή τεχνική για την συγκεκριμένη περίπτωση.

## EAAMNIKH AIMOKPATIA NAKEAONIAS

# ΠΡΟΓΡΑΜΜΑ ΜΕΤΑΠΤΥΧΙΑΚΩΝ ΣΠΟΥΔΩΝ «ΤΕΧΝΗΤΗ ΝΟΗΜΟΣΥΝΗ & ΑΝΑΛΥΤΙΚΗ ΔΕΔΟΜΕΝΩΝ»

Μηχανική Μάθηση και Επεξεργασία Φυσικής Γλώσσας

#### Οδηγίες:

- Οι εργασίες είναι **ατομικές**.
- Οι εργασίες θα πρέπει να αναρτώνται στο eClass σε ένα αρχείο zip (όχι rar) εντός της προβλεπόμενης προθεσμίας.
- Κάθε εργασία πρέπει να συνοδεύεται από:
  - (υποχρεωτικά) Το MainScript.py: αυτό είναι το βασικό αρχείο στο οποίο έχετε γράψει τον κώδικά σας. Το αρχείο πρέπει να περιέχει στις πρώτες γραμμές, μέσα σε σχόλια και με λατινικούς χαρακτήρες, τα ακόλουθα:
    - Ονοματεπώνυμο, Τμήμα, πανεπιστημιακό email και αριθμό μητρώου
  - (εφόσον ζητείται) Έναν υποφάκελο με το όνομα InputData: σε αυτό τον φάκελο θα βρίσκονται τα αρχεία τα οποία διαβάζει το πρόγραμμά σας, π.χ. txt, csv, xlsx, jpg, bmp κ.λπ.
  - (εφόσον ζητείται) Έναν υποφάκελο με το όνομα OutputData: σε αυτόν θα υπάρχει το αρχείο results.txt ή results.xlsx στο οποίο θα καταγράφονται τα αποτελέσματα της εκτέλεσης του MainScript.py καθώς και οποιοδήποτε άλλο file παράγει το MainScript.
  - ο (υποχρεωτικά) Μια **αναφορά** σε Word ή σε pdf με τα ακόλουθα στοιχεία:
    - Εξώφυλλο: 1 σελίδα, περιλαμβάνει τα στοιχεία του φοιτητή, όνομα μαθήματος, ημερομηνία, Τμήμα και λοιπές σχετικές πληροφορίες.
    - Συγκεντρωτικός πίνακας περιεχομένων, εικόνων, και λοιπών γραφημάτων που παραθέτετε στην αναφορά.
    - Ενότητα εισαγωγή: 1 σελίδα, περιγράφετε το πρόβλημα (\*χωρίς\* να αντιγράψετε αυτούσια την εκφώνηση της άσκησης)
    - Μέθοδοι που εφαρμόστηκαν: από 2 μέχρι 6 σελίδες, περιγράφετε τις μεθόδους που χρησιμοποιήσατε και παραθέτετε τα σχετικά αποτελέσματα.
      Φροντίστε να είναι ξεκάθαρο στο ποιο ερώτημα αναφέρεστε.
    - Συμπεράσματα: 1 σελίδα, με βάση τα αποτελέσματα τι προτείνετε, ποιο μοντέλο αποδίδει καλύτερα, τι θα μπορούσε να γίνει για περαιτέρω βελτίωση στην απόδοση.
    - Η αναφορά θα περιέχει γραφικές παραστάσεις κάθε είδους και πίνακες αξιολόγησης των αποτελεσμάτων που πρέπει να συνοδεύονται από μια τουλάχιστον παράγραφο με σχολιασμό.

#### Φροντίστε ώστε:

- Ο κώδικας να συνοδεύεται απαραιτήτως από κατάλληλα σχόλια.
- Να έχει γίνει συντακτικός και ορθογραφικός έλεγχος στην αναφορά που θα υποβάλετε.
- Οι προτάσεις να είναι κατανοητές και μικρές σε έκταση.

## EAAMNIKH AMMOKPATIA MAKEAONIAE

# ΠΡΟΓΡΑΜΜΑ ΜΕΤΑΠΤΥΧΙΑΚΩΝ ΣΠΟΥΔΩΝ «ΤΕΧΝΗΤΗ ΝΟΗΜΟΣΥΝΗ & ΑΝΑΛΥΤΙΚΗ ΔΕΔΟΜΕΝΩΝ»

Μηχανική Μάθηση και Επεξεργασία Φυσικής Γλώσσας

- Οι εικόνες να \*μην\* έχουν προκύψει από print screen. Αν το πρόγραμμα δημιουργεί μια εικόνα αποθηκεύστε την κανονικά (jpg ή png) και εισάγετέ την στο Word.
- Οι γραφικές παραστάσεις να περιλαμβάνουν ονόματα στους άξονες και λεζάντα, στην οποία θα παραθέτετε μια σύντομη περιγραφή για το τι είναι αυτό που βλέπουμε.
- Αν κάτι δεν διευκρινίζεται, έχετε το δικαίωμα να κάνετε **όποια υλοποίηση σας βολεύει**. Φροντίστε οι υλοποιήσεις σας να τρέχουν στον φορητό σας υπολογιστή και να μπορείτε να εξηγήσετε τι ακριβώς κάνουν όταν εξεταστείτε.
- Οι βιβλιοθήκες που θα χρησιμοποιήσετε \*πρέπει\* να μπορούν να εγκατασταθούν μέσω του pip.

Καταληκτική Ημερομηνία Παράδοσης: Πέμπτη 22 Δεκεμβρίου 2022, 23:55

Προσοχή! Δεν θα δοθεί παράταση. Κατανείμετε προσεκτικά τις ώρες εργασίας σας.